

Università Politecnica delle Marche

Facoltà di Ingegneria

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



Applicazione di Tecniche di NLP su un Dataset di Articoli di Notizie BBC News

Candidato

Erxhes Dedja — 1119284

Docenti

Prof. Domenico Ursino

Dott. Christopher Buratti

Anno Accademico 2025-2026

Indice

1	Introduzione al Natural Language Processing	1
1.1	Cos'è il Natural Language Processing?	1
1.2	Ambiti di Applicazione	1
2	Il Progetto: Dataset, Obiettivi e Tecnologie	3
2.1	Il Dataset BBC News	3
2.2	Obiettivi del Progetto	4
2.3	Tecnologie e Modelli NLP Utilizzati	4
3	Analisi Esplorativa e Pre-processing	5
3.1	Esplorazione Iniziale del Dataset	5
3.2	Pre-processing e Pulizia del Testo	6
3.2.1	Statistiche Post-Pulizia	6
3.3	Analisi Visiva e Lessicale	7
3.3.1	Esplorazione del Vocabolario	7
4	Analisi Visiva tramite WordCloud e Frequenze	9
4.1	Esplorazione del Testo con le WordCloud	9
4.2	Le 15 parole più frequenti per categoria	12
5	Sentiment Analysis con TextBlob	15
5.1	Introduzione alla Sentiment Analysis	15
5.2	Distribuzione Globale del Sentiment	15
5.3	Analisi Dettagliata per Categoria	16
5.3.1	Medie di Polarità e Soggettività	16
5.3.2	Distribuzione per Categoria	17
6	Classificazione Automatica con FastText	18
6.1	Preparazione dei Dati e partizionamento	18
6.2	Metriche di Valutazione	18
6.3	Analisi degli Errori: La Matrice di Confusione	20
7	Estrazione dell'Informazione: Named Entity Recognition	21
7.1	Introduzione al NER e scelta della libreria	21

7.2	Distribuzione generale delle entità	21
7.3	Le entità più citate: organizzazioni, persone e luoghi	22
7.3.1	Organizzazioni (ORG)	22
7.3.2	Persone (PERSON)	23
7.3.3	Luoghi e nazioni (GPE)	23

Elenco delle figure

3.1	Distribuzione del numero di articoli per ciascuna categoria tematica.	5
3.2	Numero medio di parole per articolo diviso per categoria.	6
3.3	Confronto della lunghezza degli articoli prima e dopo il pre-processing. . . .	7
3.4	Top 20 delle parole più frequenti	8
3.5	Numero di parole esclusive per ogni categoria tematica.	8
4.1	WordCloud della categoria Business.	9
4.2	WordCloud della categoria Entertainment.	10
4.3	WordCloud della categoria Politics.	10
4.4	WordCloud della categoria Sport.	11
4.5	WordCloud della categoria Tech.	11
4.6	Frequenze assolute delle Top 15 parole nella categoria Business.	12
4.7	Frequenze assolute delle Top 15 parole nella categoria Entertainment. . . .	12
4.8	Frequenze assolute delle Top 15 parole nella categoria Politics.	13
4.9	Frequenze assolute delle Top 15 parole nella categoria Sport.	13
4.10	Frequenze assolute delle Top 15 parole nella categoria Tech.	14
5.1	Distribuzione totale degli articoli classificati per Sentiment sull'intero dataset.	16
5.2	Confronto delle medie di Polarità e Soggettività tra le cinque categorie tematiche.	16
5.3	Conteggio degli articoli (Positivi, Neutri e Negativi) suddiviso per categoria.	17
6.1	Matrice di Confusione generata dalle predizioni del modello FastText. . . .	20
7.1	Mappa di calore della frequenza dei tipi di entità NER per categoria.	21
7.2	Le 8 organizzazioni (ORG) più frequentemente citate, suddivise per categoria.	22
7.3	Le 8 persone più frequentemente citate, suddivise per categoria.	23
7.4	Le 8 entità geopolitiche (Nazioni, Città, Stati) più citate per categoria. . . .	23

Capitolo 1

Introduzione al Natural Language Processing

1.1 Cos'è il Natural Language Processing?

Il Natural Language Processing (NLP) è la branca dell'intelligenza artificiale che insegna ai computer a capire il linguaggio umano.

Prima, i computer cercavano solo parole chiave nei testi. Oggi, con il NLP, capiscono il significato delle frasi, ne colgono le sfumature e riescono persino a riconoscere opinioni ed emozioni.

Oggi il NLP è fondamentale: ogni giorno produciamo miliardi di parole (email, articoli, documenti, messaggi) che nessuno potrebbe analizzare manualmente. Questa disciplina fornisce quindi gli strumenti per automatizzare la comprensione, trasformando le parole in dati numerici che i computer possono elaborare.

1.2 Ambiti di Applicazione

Le tecniche NLP si applicano a diversi ambiti, ognuno con obiettivi specifici. Le applicazioni principali che trattiamo in questo progetto sono:

- **Text Classification (Classificazione del Testo):** Consiste nell'addestrare un modello ad assegnare automaticamente una categoria a un documento in base al suo contenuto. È una tecnologia che permette a un computer di catalogare i testi in automatico, intuendo subito se un articolo tratta di politica, economia o sport.
- **Sentiment Analysis (Analisi del Sentiment):** misura se un testo esprime emozioni positive, negative o neutre (polarità) e quanto è oggettivo o soggettivo.
- **Information Extraction:** identificare automaticamente persone, aziende, luoghi (NER) e frasi chiave per riassumere il contenuto di un testo.

L'evoluzione di queste tecnologie ha visto il passaggio dai vecchi modelli statistici, che si limitavano a contare le occorrenze delle parole, a moderne architetture basate su reti neurali e *embeddings*.

Capitolo 2

Il Progetto: Dataset, Obiettivi e Tecnologie

2.1 Il Dataset BBC News

I dati utilizzati per l'analisi provengono dal [BBC News Archive](#), una raccolta originariamente messa a disposizione dalla BBC come punto di riferimento per la ricerca nel campo del Machine Learning e oggi scaricabile pubblicamente dalla piattaforma Kaggle.

Il dataset contiene 2.225 articoli in inglese, pubblicati sul sito della BBC tra il 2004 e il 2005. Scritti da giornalisti professionisti, questi articoli hanno un linguaggio formale e riferimenti a fatti reali.

Il dataset è un file di testo dove ogni riga è un articolo. Di seguito vengono descritte tutte le colonne presenti al suo interno:

Colonna	Descrizione
category	La macro-categoria tematica a cui appartiene la notizia. I valori possibili sono cinque: <i>business</i> , <i>entertainment</i> , <i>politics</i> , <i>sport</i> , <i>tech</i> .
filename	Il nome originario del file di testo da cui è stato estratto l'articolo (es. <i>001.txt</i>). Viene utilizzato come identificativo univoco per ogni documento all'interno della sua categoria.
title	Il titolo originale dell'articolo pubblicato dalla BBC.
content	Il corpo del testo, contenente l'intero articolo giornalistico.

Tabella 2.1: Descrizione di tutte le colonne presenti nel dataset BBC News

Abbiamo scelto questo dataset perché è bilanciato: ogni categoria ha un numero simile di articoli. Questo è un fattore ingegneristico fondamentale per evitare problemi di sbilanciamento (*overfitting*) durante la successiva fase di classificazione automatica.

2.2 Obiettivi del Progetto

L'obiettivo di questo elaborato è sviluppare un sistema che analizzi gli articoli da più prospettive. Il sistema risponde a quattro obiettivi principali:

1. Pulire il testo rimuovendo la punteggiatura, link e parole inutili per concentrarci sul contenuto importante.
2. Esplorare i vocaboli più utilizzati tramite rappresentazioni grafiche e misurare automaticamente il *sentiment* e lo stile editoriale degli articoli.
3. Addestrare un modello che, dato un testo nuovo, ne indovini la categoria (es.: sport, politica, economia).
4. Estrarre informazioni chiave: identificare automaticamente chi (persone, aziende), dove (luoghi) e cosa (temi principali) viene menzionato.

2.3 Tecnologie e Modelli NLP Utilizzati

Per risolvere i diversi compiti, non abbiamo usato un unico modello complesso, ma più strumenti specializzati. Il lavoro è stato diviso in diverse fasi e le tecnologie principali impiegate sono:

- **TextBlob:** misura il tono emotivo di un testo. Usa un dizionario interno per assegnare un punteggio alle parole. Assegna due punteggi: polarità (da -1 a +1, per misurare se il testo è positivo o negativo) e soggettività (da 0 a 1, per misurare se il testo è oggettivo o soggettivo).
- **FastText:** Scelto come algoritmo di *Text Classification*, classifica gli articoli per categoria. Analizza anche coppie di parole (es. 'New York') per capire meglio il contesto. Questo lo rende molto veloce da addestrare e robusto anche con errori di battitura o parole nuove.
- **spaCy:** Impiegato per il *Named Entity Recognition* (NER). A differenza di altre librerie nate per scopi accademici, spaCy è progettata per l'uso industriale. Sfrutta modelli statistici pre-addestrati per scansionare il testo e classificare le entità presenti, distinguendo ad esempio un nome di persona da quello di un'azienda o di una nazione.

Capitolo 3

Analisi Esplorativa e Pre-processing

3.1 Esplorazione Iniziale del Dataset

Il primo passo è stato quello di caricare i dati e verificarne l'integrità. Il dataset è composto da 2.225 articoli, senza alcun valore mancante o nullo.

Per comprendere meglio la natura dei documenti, abbiamo analizzato la distribuzione degli articoli tra le varie categorie tematiche.




Figura 3.1: Distribuzione del numero di articoli per ciascuna categoria tematica.

Come mostra la Figura 3.1, il dataset risulta molto ben bilanciato. Le categorie *Sport* e *Business* sono le più corpose, seguite da *Politics*, *Tech* ed *Entertainment*. Il bilanciamento tra le categorie è ideale per addestrare un modello di Machine Learning.




Figura 3.2: Numero medio di parole per articolo diviso per categoria.

Osservando invece la lunghezza dei testi (Figura 3.2), emerge che gli articoli della categoria *Tech* sono mediamente i più lunghi, seguiti da *Politics*. Le altre tre categorie si assestano su testi più brevi e compatti, intorno alle 325 parole.

3.2 Pre-processing e Pulizia del Testo

Anche se gli articoli sono ben scritti, contengono elementi inutili (punteggiatura, link, parole comuni) che vanno rimossi prima dell'analisi. Per mantenere solo l'effettivo nucleo semantico delle notizie, abbiamo applicato una pipeline di pulizia articolata in tre passaggi chiave:

- **Conversione in minuscolo (*lowercasing*):** Tutto il testo è stato convertito in minuscolo per far sì che la macchina tratti parole identiche scritte con maiuscole o minuscole allo stesso modo.
- **Rimozione del rumore:** Tramite espressioni regolari, sono stati eliminati link, numeri e punteggiatura, mantenendo solo le lettere.
- **Filtro delle Stop-Words:** oltre alle parole vuote standard (es.: 'il', 'e'), sono state aggiunte stop-words specifiche per il linguaggio giornalistico (es.: 'said', 'new').

3.2.1 Statistiche Post-Pulizia

Per avere un quadro numerico del lavoro svolto, abbiamo estratto le metriche descrittive degli articoli raggruppati per categoria dopo la fase di pulizia, riportate nella Tabella 3.1.

Categoria	Articoli	Media parole	Mediana	Max	Min	Vocabolario	Media titolo
Business	510	323.5	292.0	885	136	11.676	5.4
Entertainment	386	325.2	256.5	3477	138	11.778	5.4
Politics	417	448.9	434.0	4428	84	11.232	5.1
Sport	511	324.4	282.0	1656	108	10.815	4.9
Tech	401	497.4	441.0	2964	157	12.276	5.3

Tabella 3.1: Statistiche descrittive degli articoli raggruppati per categoria tematica

I dati confermano che la categoria *Tech* possiede il vocabolario più ricco (12.276 parole uniche), coerentemente con l’alto numero di termini tecnici del settore informatico. Lo *Sport*, invece, utilizza un linguaggio più ristretto e standardizzato.

3.3 Analisi Visiva e Lessicale

Per vedere l’effetto della pulizia, abbiamo confrontato la lunghezza degli articoli prima e dopo usando i *boxplot*.




Figura 3.3: Confronto della lunghezza degli articoli prima e dopo il pre-processing.

Come si evince dalla Figura 3.3, il volume di parole per ogni articolo si è drasticamente ridotto (le "scatole" si sono abbassate notevolmente). Questo dimostra che rimuovendo punteggiatura e stop-words abbiamo mantenuto solo le parole utili.

3.3.1 Esplorazione del Vocabolario

Una volta ottenuti i testi puliti, abbiamo esplorato il vocabolario per capire quali sono i concetti che guidano la narrazione, partendo dalle venti parole più ricorrenti in assoluto.




Figura 3.4: Top 20 delle parole più frequenti

Il grafico in Figura 3.4 mette in risalto le tematiche calde del periodo 2004-2005.





Figura 3.5: Numero di parole esclusive per ogni categoria tematica.

Per capire quanto le categorie fossero distinte a livello di lessico, abbiamo contato le parole "esclusive" (ovvero quelle che compaiono in una sola categoria e in nessun'altra).

Analisi Visiva tramite WordCloud e Frequenze

Per generare queste nuvole di parole per ciascuna delle cinque categorie del nostro dataset, abbiamo utilizzato la libreria omonima **wordcloud** in Python.



Nella categoria **Business** dominano, come prevedibile, i termini legati all'economia e alla finanza. Parole come *market*, *company*, *firm*, *economy* e *bank* spiccano al centro della scena, riflettendo in modo esatto le dinamiche aziendali e l'andamento dei mercati.




Figura 4.2: WordCloud della categoria Entertainment.

Passando all'ambito **Entertainment**, i concetti chiave sono fortemente legati al mondo dello spettacolo, del cinema e della musica. Troviamo infatti in grande evidenza vocaboli come *film*, *music*, *award*, *star* e *best*.




Figura 4.3: WordCloud della categoria Politics.

La nuvola della **Politics** restituisce una fotografia storica delle istituzioni e dei leader del periodo (2004-2005). L'attenzione è catturata in modo schiacciante dalla parola *government*, circondata da termini come *election*, *blair*, *party* e *minister*.




Figura 4.4: WordCloud della categoria Sport.

Nella categoria **Sport** i termini dominanti sono *game*, *win*, *player*, *match* ed *england*, a dimostrazione di un linguaggio molto diretto e orientato ai risultati.




Figura 4.5: WordCloud della categoria Tech.

Infine, per la categoria **Tech** emergono chiaramente i riferimenti all'innovazione e al mondo digitale.

4.2 Le 15 parole più frequenti per categoria

L'analisi successiva consiste nell'estrarre e quantificare le frequenze assolute delle 15 parole più utilizzate all'interno di ogni singola categoria, per capire non solo quali parole vengono usate, ma quanto dominano il testo.




Figura 4.6: Frequenze assolute delle Top 15 parole nella categoria Business.

Nel settore **Business**, la parola *market* guida la classifica superando le 400 occorrenze, seguita a ruota da *growth* e *company*. La discesa delle frequenze è abbastanza graduale: questo indica che il vocabolario economico è ben distribuito su più concetti chiave, senza un singolo termine che monopolizzi del tutto i testi.




Figura 4.7: Frequenze assolute delle Top 15 parole nella categoria Entertainment.

Per la categoria **Entertainment**, la situazione è molto diversa. Il termine *film* domina in modo assoluto sfiorando le 700 presenze, staccando nettamente *music* e *show*. Questo forte divario riflette la massiccia presenza di recensioni, resoconti di premiazioni (come gli Oscar) e notizie cinematografiche all'interno di questa sezione della BBC.




Figura 4.8: Frequenze assolute delle Top 15 parole nella categoria Politics.

Nella **Politics**, la parola *government* è il vero e proprio fulcro del discorso con quasi 650 occorrenze, tallonata da *labour* ed *election*.




Figura 4.9: Frequenze assolute delle Top 15 parole nella categoria Sport.

Negli articoli sportivi abbiamo termini come *game* e *win*. Entrambe le parole sfiorano o superano le 400 occorrenze, confermando un linguaggio incentrato quasi unicamente sulla

cronaca della competizione.




Figura 4.10: Frequenze assolute delle Top 15 parole nella categoria Tech.

Infine, in **Tech** la classifica è guidata da *technology* e *mobile*, subito seguite da *users* e *games*. Anche in questo caso le frequenze scendono in modo molto progressivo tra la prima e la quindicesima posizione, evidenziando l'ampia varietà di argomenti trattati nella sezione.

Capitolo 5

Sentiment Analysis con TextBlob

5.1 Introduzione alla Sentiment Analysis

Dopo aver capito *quali* parole vengono usate di più, il passo successivo è stato analizzare *come* vengono usate. L'obiettivo della Sentiment Analysis è insegnare al computer a riconoscere il tono emotivo di un testo. Per farlo abbiamo scelto **TextBlob**, uno strumento in Python pratico e veloce. Invece di usare complesse reti neurali, TextBlob funziona come un vero e proprio "dizionario delle emozioni": conosce già il peso emotivo di tantissime parole (se sono positive o negative). Il sistema legge l'articolo, fa la media di questi pesi e restituisce due punteggi finali:

- **Polarità (*Polarity*):** È un numero che varia da -1 (testo estremamente negativo) a $+1$ (testo estremamente positivo). Uno zero indica un tono perfettamente neutro o distaccato.
- **Soggettività (*Subjectivity*):** È un valore compreso tra 0 e 1. Più si avvicina allo zero, più il testo è oggettivo e basato sui fatti; più si avvicina a uno, più esprime opinioni, emozioni e giudizi personali dell'autore.

5.2 Distribuzione Globale del Sentiment

Per avere una visione chiara e quantificabile, abbiamo tradotto i valori continui di polarità in tre etichette nette:

- **Positivo:** polarità > 0.05
- **Negativo:** polarità < -0.05
- **Neutro:** polarità compresa tra -0.05 e 0.05

La prima analisi riguarda l'intero dataset, calcolando il sentiment totale su tutti i 2.225 documenti senza distinzione di categoria.




Figura 5.1: Distribuzione totale degli articoli classificati per Sentiment sull'intero dataset.

Come si osserva nella Figura 5.1, a maggior parte degli articoli ha un tono positivo o neutro. Su 2225 articoli, 1555 (70%) sono positivi, mentre solo 112 sono negativi. Questo mostra che, contrariamente ai pregiudizi, gli articoli parlano soprattutto di successi, crescita e innovazione.

5.3 Analisi Dettagliata per Categoria

Se il dataset globale appare molto positivo, è analizzando le singole categorie che emergono le differenze più interessanti nello stile editoriale.

5.3.1 Medie di Polarità e Soggettività

Abbiamo calcolato i punteggi medi di polarità e soggettività raggruppando gli articoli in base all'argomento trattato, ottenendo il confronto visibile in Figura 5.2.




Figura 5.2: Confronto delle medie di Polarità e Soggettività tra le cinque categorie tematiche.

La figura mostra che Entertainment ha la polarità media più alta (0,15), seguita da

Sport e Tech. È un risultato coerente: recensioni di film, vittorie sportive e lanci di prodotti usano spesso parole entusiastiche. Politics e Business hanno polarità più basse, a causa di argomenti come crisi economiche o sconfitte elettorali.

Per quanto riguarda la soggettività, i punteggi medi si aggirano tutti intorno a 0.4. Questo significa che, anche se scritti da giornalisti, gli articoli contengono sempre un po' di interpretazione personale, soprattutto in Tech e Entertainment.

5.3.2 Distribuzione per Categoria

Infine, abbiamo visto come sono distribuite le etichette (positivo, neutro, negativo) per ogni categoria, per capire dove la cronaca è più 'dura'.




Figura 5.3: Conteggio degli articoli (Positivi, Neutri e Negativi) suddiviso per categoria.

La Figura 5.3 conferma l'osservazione precedente. Sebbene in tutte le categorie le barre verdi (Positivo) siano le più alte, è nel Business che troviamo più articoli neutri e negativi: la cronaca finanziaria, fatta di dati e percentuali, porta naturalmente a un tono più distaccato e spesso costretta a riportare perdite e recessioni. Anche in *Sport* si nota una fetta di articoli negativi (legati presumibilmente a sconfitte o infortuni), ma superata dalle vittorie (quasi 400 articoli positivi).

Capitolo 6

Classificazione Automatica con FastText

6.1 Preparazione dei Dati e partizionamento

Dopo la pulizia e l'analisi esplorativa, abbiamo addestrato un modello che classifica automaticamente gli articoli in una delle cinque categorie.

Come anticipato, per questo compito è stato scelto **FastText** che analizza le parole scomponendole in parti più piccole (es.: prefissi, suffissi), ed è molto veloce da addestrare e robusto.

Il primo passaggio pratico è stato dividere il dataset. L'intero corpus è stato suddiviso utilizzando il classico schema 80/20:

- **Training Set (80%):** 1.780 articoli utilizzati per addestrare il modello.
- **Test Set (20%):** 445 articoli "nascosti" al modello durante il training e usati esclusivamente per valutarne le prestazioni finali.

Un vantaggio di questo dataset è che le categorie sono già bilanciate (da 386 a 511 articoli ciascuna). Anche nel set di addestramento le categorie sono bilanciate (es.: 409 per Sport, 408 per Business, 309 per Entertainment). Grazie a questo bilanciamento, non abbiamo dovuto usare tecniche complesse per bilanciare i dati, e il modello si è addestrato solo su articoli reali.

6.2 Metriche di Valutazione

Dopo l'addestramento, abbiamo testato FastText sui 445 articoli del Test Set. I risultati ottenuti sono stati ottimi, registrando un'**Accuracy globale del 99%**.

Per avere un quadro più dettagliato delle performance, abbiamo estratto il *Classification Report*, che calcola per ogni classe tre metriche fondamentali:

- **Precision:** percentuale di articoli classificati correttamente in una categoria (evita falsi positivi).

- **Recall:** percentuale di articoli di una categoria trovati dal modello (evita falsi negativi).
- **F1-Score:** media tra precisione e recall, per un'unica misura di affidabilità.

I risultati sono riassunti nella Tabella 6.1.

Categoria	Precision	Recall	F1-Score	Supporto (Test Set)
Business	1.00	0.96	0.98	102
Entertainment	1.00	1.00	1.00	77
Politics	0.98	0.99	0.98	84
Sport	0.99	1.00	1.00	102
Tech	0.98	1.00	0.99	80
Accuracy Globale	0.99			445

Tabella 6.1: Report di classificazione del modello FastText sul Test Set.

Sulle categorie *Entertainment* e *Sport*, il modello raggiunge un F1-Score di 1.00, identificando senza alcun errore tutti i documenti.

6.3 Analisi degli Errori: La Matrice di Confusione

Anche se le metriche sono ottime, è importante vedere dove il modello sbaglia, anche se gli errori sono pochi. Lo strumento principale è la matrice di confusione, che confronta le categorie reali (righe) con quelle previste dal modello (colonne).




Figura 6.1: Matrice di Confusione generata dalle predizioni del modello FastText.

Nella Figura 6.1, la diagonale principale (predizioni corrette) mostra che il modello è molto stabile. Su 445 articoli, il modello ha sbagliato solo 5 volte. Analizzando questi errori, possiamo capire come funziona:

- **Business confuso con altro:** 2 articoli sono stati classificati come Politics, 1 come Sport e 1 come Tech (4 errori in totale).
- **Politics confuso con Tech:** 1 articolo di Politics è stato erroneamente classificato come Tech.
- **Altre categorie immacolate:** Entertainment, Sport e Tech non hanno alcun falso negativo (tutti i loro articoli sono stati classificati correttamente).

In conclusione, l’addestramento con FastText ha restituito un sistema estremamente robusto e affidabile, pienamente capace di comprendere e categorizzare la semantica di un articolo di giornale.

Capitolo 7

Estrazione dell'Informazione: Named Entity Recognition

7.1 Introduzione al NER e scelta della libreria

Classificare un articolo e analizzarne il tono è utile, ma non ci dice chi sono i protagonisti. Il *Named Entity Recognition* (NER) identifica automaticamente chi (persone), cosa (organizzazioni) e dove (luoghi) vengono menzionati in un testo.

Per questo compito è stata scelta **spaCy**, una libreria open-source usata sia in ambito accademico che industriale. spaCy non cerca solo parole in un dizionario, ma analizza il contesto: sa che 'Blair' è una persona, non un aggettivo. Per il testo in lingua inglese è stato utilizzato il modello `en_core_web_sm` che classifica le entità come: PERSON (persone), ORG (organizzazioni), GPE (luoghi).

7.2 Distribuzione generale delle entità

Prima di vedere i nomi specifici, è utile capire quante e quali entità compaiono in ogni categoria.




Figura 7.1: Mappa di calore della frequenza dei tipi di entità NER per categoria.

Si notano subito alcune differenze interessanti tra le categorie:

- **Sport:** La categoria con il maggior numero di entità di tipo PERSON, con oltre 3.600 occorrenze. Conferma quello che ci si aspetta: la cronaca sportiva ruota quasi interamente attorno agli atleti.
- **Business:** la categoria con più organizzazioni (aziende, banche) e l'unica con l'etichetta MONEY.
- **Entertainment:** equilibrio tra persone (attori, musicisti) e organizzazioni (case discografiche).

Ogni categoria ha un profilo diverso di entità, che riflette le differenze tematiche già viste.

7.3 Le entità più citate: organizzazioni, persone e luoghi

Dopo aver visto la distribuzione generale, abbiamo analizzato le entità più citate in ogni categoria: organizzazioni, persone e luoghi.

7.3.1 Organizzazioni (ORG)




Figura 7.2: Le 8 organizzazioni (ORG) più frequentemente citate, suddivise per categoria.

I risultati in Figura 7.2 rispecchiano bene il contesto storico del 2004-2005. In *Tech* dominano i grandi nomi dell'informatica dell'epoca: Microsoft, Sony, Apple, Google. In *Politics* compaiono i partiti e le istituzioni europee, con Labour e Parliament in cima. Nello Sport le organizzazioni sono i principali club calcistici inglesi, come Chelsea, Arsenal e Liverpool. Vale la pena notare che la BBC compare con una certa frequenza in quasi tutte le categorie, il che è logico trattandosi della testata autrice degli articoli stessi.

7.3.2 Persone (PERSON)




Figura 7.3: Le 8 persone più frequentemente citate, suddivise per categoria.

Il grafico delle persone in Figura 7.3 è forse il più immediato da leggere. In *Politics* domina Tony Blair (Primo Ministro), seguito da Gordon Brown e Michael Howard. In *Entertainment* compaiono nomi come Ray Charles, Elvis Presley e Leonardo DiCaprio. In *Business* ci sono meno nomi di persona: spaCy a volte confonde aziende con persone, un limite noto dei modelli NER.

7.3.3 Luoghi e nazioni (GPE)




Figura 7.4: Le 8 entità geopolitiche (Nazioni, Città, Stati) più citate per categoria.

La Figura 7.4 mostra che, essendo un corpus britannico, UK, Britain, England, London e USA sono tra i luoghi più citati. Le differenze si vedono dopo: in Business compaiono Cina, Russia, Giappone, India; in Politics spicca l'Iraq (tema centrale nel 2004-2005). In *Sport* i luoghi coincidono invece con le città che ospitavano i principali eventi sportivi del periodo.