

**UNIVERSITÀ POLITECNICA DELLE MARCHE**

**FACOLTÀ DI INGEGNERIA**

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione

---



# **Analisi Python**

## **Dataset Londra**

**Autori del progetto**

Erxhes Dedja - 1119284

**Docenti**

Prof. Domenico Ursino

---

**ANNO ACCADEMICO 2024-2025**

# Indice

---

|          |                                                                |           |
|----------|----------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduzione</b>                                            | <b>1</b>  |
| 1.1      | ETL . . . . .                                                  | 2         |
| <b>2</b> | <b>Analisi Descrittiva</b>                                     | <b>3</b>  |
| 2.1      | Precipitazioni . . . . .                                       | 3         |
| 2.2      | Temperatura . . . . .                                          | 6         |
| 2.2.1    | Andamento delle temperature . . . . .                          | 6         |
| 2.2.2    | Distribuzione stagionale e mensile delle temperature . . . . . | 7         |
| 2.3      | Relazione Tra Temperatura E Precipitazioni . . . . .           | 9         |
| 2.4      | Analisi Aggiuntive . . . . .                                   | 11        |
| <b>3</b> | <b>Classificazione</b>                                         | <b>14</b> |
| 3.1      | Pre-processing dei dati . . . . .                              | 14        |
| 3.1.1    | Gestione dei valori mancanti . . . . .                         | 14        |
| 3.1.2    | Feature engineering . . . . .                                  | 14        |
| 3.1.3    | Creazione del target binario . . . . .                         | 15        |
| 3.1.4    | Riduzione della multicollinearità . . . . .                    | 15        |
| 3.1.5    | Split temporale e gestione dello sbilanciamento . . . . .      | 17        |
| 3.2      | Training dei dati . . . . .                                    | 17        |
| 3.3      | Risultati della Classificazione . . . . .                      | 18        |
| 3.4      | Metriche dettagliate per classificatore . . . . .              | 19        |
| 3.5      | Curve ROC . . . . .                                            | 21        |
| 3.6      | Ottimizzazione degli Iperparametri con Grid Search . . . . .   | 22        |
| 3.7      | Matrice di correlazione tra le predizioni . . . . .            | 22        |
| 3.8      | Modello ensemble: Voting Classifier . . . . .                  | 23        |
| 3.8.1    | Risultati con soglia predefinita (0.5) . . . . .               | 23        |
| 3.8.2    | Ottimizzazione della soglia di classificazione . . . . .       | 24        |
| 3.8.3    | Curva ROC e Precision-Recall . . . . .                         | 25        |
| 3.8.4    | Learning Curve . . . . .                                       | 26        |
| 3.9      | Conclusioni sulla classificazione . . . . .                    | 27        |
| <b>4</b> | <b>Clustering</b>                                              | <b>29</b> |
| 4.1      | Clustering delle Temperature . . . . .                         | 29        |

---

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| 4.1.1    | K-Means Clustering . . . . .                                | 31        |
| 4.1.2    | Validazione e confronto con Clustering Gerarchico . . . . . | 32        |
| 4.2      | Clustering su Radiazione Solare e Precipitazioni . . . . .  | 33        |
| 4.2.1    | Risultati del K-Means . . . . .                             | 34        |
| 4.2.2    | Confronto con il Clustering Gerarchico . . . . .            | 36        |
| 4.3      | Analisi con PCA e DBSCAN . . . . .                          | 37        |
| 4.3.1    | Riduzione dimensionale e K-Means su PCA . . . . .           | 37        |
| 4.3.2    | DBSCAN . . . . .                                            | 37        |
| 4.4      | Conclusioni del Clustering . . . . .                        | 38        |
| <b>5</b> | <b>Analisi Temporale</b>                                    | <b>40</b> |
| 5.1      | Preparazione dei dati e stazionarietà . . . . .             | 40        |
| 5.2      | Scelta dei parametri $p$ e $q$ . . . . .                    | 41        |
| 5.3      | Modelli ARIMA . . . . .                                     | 43        |
| 5.4      | Validazione out-of-time . . . . .                           | 44        |
| 5.5      | Modello SARIMAX . . . . .                                   | 45        |
| 5.6      | Conclusioni sull'analisi temporale . . . . .                | 46        |

---

# Elenco delle figure

---

|      |                                                                                                                                                                                                                                                                                                   |    |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1  | Giorni Di Pioggia . . . . .                                                                                                                                                                                                                                                                       | 3  |
| 2.2  | Anomalia percentuale della precipitazione annuale (1979-2020). .                                                                                                                                                                                                                                  | 4  |
| 2.3  | Istogramma Precipitazioni Londra . . . . .                                                                                                                                                                                                                                                        | 5  |
| 2.4  | Anomalia delle temperature annuali. . . . .                                                                                                                                                                                                                                                       | 6  |
| 2.5  | Distribuzione temperature medie stagionali . . . . .                                                                                                                                                                                                                                              | 7  |
| 2.6  | Distribuzione della temperatura massima per mese . . . . .                                                                                                                                                                                                                                        | 8  |
| 2.7  | Precipitazione media per fasce termiche . . . . .                                                                                                                                                                                                                                                 | 9  |
| 2.8  | Relazione tra Temperatura Media e Precipitazioni . . . . .                                                                                                                                                                                                                                        | 10 |
| 2.9  | PairPlot variabili meteorologiche . . . . .                                                                                                                                                                                                                                                       | 11 |
| 2.10 | HeatMap variabili meteorologiche . . . . .                                                                                                                                                                                                                                                        | 13 |
| 3.1  | Heatmap delle correlazioni tra tutte le variabili numeriche originali e il target $y$ . La riga $y$ mostra il potere predittivo iniziale di ciascuna variabile: correlazione negativa con <code>sunshine</code> e positiva con <code>cloud_cover</code> , coerenti con le attese fisiche. . . . . | 16 |
| 3.2  | Heatmap dopo la rimozione di <code>max_temp</code> , <code>mean_temp</code> , <code>min_temp</code> e <code>global_radiation</code> . . . . .                                                                                                                                                     | 17 |
| 3.3  | Barplot dei punteggi F1-weighted in cross-validazione temporale (TimeSeriesSplit, 5 fold). Le barre di errore rappresentano la deviazione standard. . . . .                                                                                                                                       | 19 |
| 3.4  | Matrici di confusione per tutti e cinque i classificatori sul test set. Righe: valori reali; colonne: predizioni. . . . .                                                                                                                                                                         | 19 |
| 3.5  | Curve ROC per i cinque classificatori sul test set. La diagonale tratteggiata rappresenta un classificatore casuale (AUC = 0.5). . .                                                                                                                                                              | 21 |
| 3.6  | Matrice di correlazione tra le predizioni dei cinque classificatori sul test set. . . . .                                                                                                                                                                                                         | 23 |
| 3.7  | Matrice di confusione del Voting Classifier con soglia 0.5. . . . .                                                                                                                                                                                                                               | 24 |
| 3.8  | Confronto delle matrici di confusione: soglia 0.5 (sinistra) vs soglia ottimale 0.377 (destra). . . . .                                                                                                                                                                                           | 25 |
| 3.9  | Curva ROC del Voting Classifier ottimizzato (AUC $\approx 0.89$ ). . . . .                                                                                                                                                                                                                        | 25 |
| 3.10 | Curva Precision-Recall del Voting Classifier. . . . .                                                                                                                                                                                                                                             | 26 |
| 3.11 | Learning Curve con Yellowbrick (TimeSeriesSplit, 5 fold). . . . .                                                                                                                                                                                                                                 | 26 |
| 3.12 | Learning Curve con scikit-learn (bande = deviazione standard). .                                                                                                                                                                                                                                  | 27 |

|      |                                                                                                                              |    |
|------|------------------------------------------------------------------------------------------------------------------------------|----|
| 4.1  | Metodo Elbow per il clustering delle Temperature. . . . .                                                                    | 30 |
| 4.2  | Punteggi Silhouette per il clustering delle Temperature. . . . .                                                             | 30 |
| 4.3  | K-Means Clustering delle Temperature (max_temp e mean_temp standardizzate). . . . .                                          | 31 |
| 4.4  | Silhouette Plot per K-Means sulle temperature ( $k = 4$ ). . . . .                                                           | 32 |
| 4.5  | Clustering Gerarchico Agglomerativo delle Temperature. . . . .                                                               | 33 |
| 4.6  | Metodo del Gomito per Radiazione e Precipitazioni. . . . .                                                                   | 33 |
| 4.7  | Punteggi Silhouette per Radiazione e Precipitazioni. . . . .                                                                 | 34 |
| 4.8  | K-Means Clustering: Precipitazioni vs Radiazione Solare ( $k = 4$ ). . . . .                                                 | 35 |
| 4.9  | Silhouette Plot per K-Means su Radiazione e Precipitazioni. . . . .                                                          | 36 |
| 4.10 | Clustering Gerarchico Agglomerativo: Precipitazioni vs Radiazione Solare. . . . .                                            | 36 |
| 4.11 | Cluster K-Means nello spazio delle componenti principali. . . . .                                                            | 37 |
| 4.12 | Grafico delle distanze per la scelta di $\epsilon$ . . . . .                                                                 | 37 |
| 4.13 | Cluster DBSCAN visualizzati sulle componenti principali. . . . .                                                             | 38 |
| 5.1  | Andamento generale delle precipitazioni (1979-2020). . . . .                                                                 | 40 |
| 5.2  | Precipitazioni giornaliere nel periodo 2016-2020. . . . .                                                                    | 40 |
| 5.3  | Precipitazioni giornaliere nell'anno 2020. . . . .                                                                           | 41 |
| 5.4  | Autocorrelazione (ACF) della serie delle precipitazioni. . . . .                                                             | 42 |
| 5.5  | Autocorrelazione parziale (PACF) della serie delle precipitazioni. . . . .                                                   | 42 |
| 5.6  | Decomposizione stagionale della serie delle precipitazioni. . . . .                                                          | 43 |
| 5.7  | Residui del modello ARIMA(1,0,1). . . . .                                                                                    | 43 |
| 5.8  | Previsione con ARIMA(1,0,1) per l'anno 2021. . . . .                                                                         | 44 |
| 5.9  | Validazione out-of-time: training (blu), valori reali (arancione) e previsioni (verde) con intervallo di confidenza. . . . . | 44 |
| 5.10 | Modello SARIMAX(1,0,1)(0,1,1) <sub>12</sub> : valori osservati e valori stimati. . . . .                                     | 45 |
| 5.11 | Previsione delle precipitazioni per l'anno 2021 con SARIMAX e relativo intervallo di confidenza. . . . .                     | 46 |

# Capitolo 1

## Introduzione

---

Il dataset utilizzato per l'analisi contiene tutte le osservazioni meteorologiche giornaliere raccolte a Londra dal 1979 al 2021.

I dati provengono dall'European Climate Assessment & Dataset (ECA&D), un progetto che raccoglie e distribuisce dati climatici per l'Europa.

Il dataset in questione: <https://www.kaggle.com/datasets/emmanuelwerr/london-weather-data>

| Variabile | Descrizione                                                        |
|-----------|--------------------------------------------------------------------|
| DATE      | Data delle osservazioni nel formato YYYYMMDD.                      |
| TX        | Temperatura massima (in decimi di grado Celsius, 0.1°C).           |
| TN        | Temperatura minima (in decimi di grado Celsius, 0.1°C).            |
| TG        | Temperatura media giornaliera (in decimi di grado Celsius, 0.1°C). |
| SS        | Durata del sole (in decimi di ora).                                |
| SD        | Profondità della neve al suolo (in cm).                            |
| RR        | Precipitazioni giornaliere (in decimi di mm).                      |
| QQ        | Radiazione globale solare (in watt per metro quadrato).            |
| PP        | Pressione atmosferica al livello del mare (in decimi di hPa).      |
| HU        | Umidità relativa dell'aria (in percentuale).                       |
| CC        | Copertura nuvolosa (misurata in ottavi, oktas).                    |

**Tabella 1.1:** Descrizione delle variabili meteorologiche

## 1.1 ETL

---

La fase iniziale del progetto si è concentrata sulla preparazione del dataset per le analisi successive. Questo processo, noto come ETL (Extract, Transform, Load), è fondamentale per garantire la qualità e la coerenza dei dati.

Le operazioni eseguite sono state le seguenti:

1. **Caricamento del Dataset:** I dati sono stati caricati da un file `london_weather.csv` in un DataFrame pandas.
2. **Conversione della Data:** La colonna `date`, originariamente in formato numerico (es. 20211231), è stata convertita in un oggetto `datetime` standard. Questa trasformazione è cruciale per abilitare analisi basate sul tempo.
3. **Ingegneria delle Feature Temporali:** Dalla colonna `date` sono state estratte tre nuove colonne numeriche: `day`, `month` e `year`. È stata inoltre creata una colonna testuale, `month_name`, per associare il numero del mese al suo nome in italiano (es. 1 -> 'Gennaio'), facilitando la leggibilità dei grafici.
4. **Gestione dei Valori Mancanti:** È stata identificata la presenza di dati mancanti in diverse colonne. Per evitare la perdita di informazioni, i valori nulli nelle seguenti variabili sono stati sostituiti con la media dei valori presenti nella rispettiva colonna:
  - `cloud_cover`
  - `global_radiation`
  - `max_temp`
  - `mean_temp`
  - `min_temp`
  - `precipitation`
  - `pressure`
  - `snow_depth`

Questo approccio assicura che il dataset sia completo e pronto per le fasi di analisi descrittiva, classificazione e clustering.


## Capitolo 2

# Analisi Descrittiva

In questo capitolo l'obiettivo principale è quello di fornire una panoramica chiara e comprensibile delle caratteristiche principali del nostro dataset.

### 2.1 Precipitazioni

Il grafico classifica le giornate in base all'intensità della pioggia registrata. Osservare il numero di giorni e le rispettive percentuali ci permette di capire in modo chiaro quali sono le condizioni meteorologiche più tipiche del periodo.



**Figura 2.1:** Giorni Di Pioggia


Il dato primario che emerge è la netta prevalenza di giornate secche o con precipitazioni non significative: i giorni classificati come "Asciutto" (con accumuli inferiori a 0.1 mm) sono ben 8291, rappresentando la maggioranza assoluta del campione totale (54.0%).

Per quanto concerne invece le giornate caratterizzate da precipitazioni misurabili, si osserva una proporzionalità inversa tra l'intensità dell'evento meteorologico e la sua frequenza temporale. Nello specifico:

- **Pioggia leggera (0.1 - 2.5 mm):** Costituisce la tipologia di evento piovoso più comune, con 4050 giorni registrati, pari al 26.4% del totale.
- **Pioggia moderata (2.5 - 10 mm):** Si attesta al 15.8% del campione analizzato, corrispondente a 2421 giornate.
- **Pioggia forte (> 10 mm):** Rappresenta la casistica di gran lunga meno frequente. Solamente in 579 occasioni, pari ad appena il 3.8% dei giorni totali, le precipitazioni hanno superato la soglia di accumulo dei 10 mm giornalieri.

In sintesi, Londra è caratterizzata da una predominanza di tempo asciutto. Quando si verificano eventi precipitativi, questi tendono a essere prevalentemente di debole o moderata intensità, mentre gli episodi di pioggia abbondante o intensa costituiscono eventi meteorologici piuttosto rari ed eccezionali nel contesto statistico generale.

Il secondo grafico rappresenta l'anomalia percentuale delle precipitazioni annuali rispetto alla media climatologica di riferimento calcolata sul trentennio 1981-2010 (pari a circa 602 mm). L'andamento temporale, che si estende per un quarantennio, evidenzia una marcata variabilità interannuale tipica del regime pluviometrico analizzato, senza mostrare un trend lineare unidirezionale a lungo termine.



**Figura 2.2:** Anomalia percentuale della precipitazione annuale (1979-2020).


Si osserva una netta alternanza tra annate più umide della media (valori positivi) e annate deficitarie (valori negativi). Analizzando i valori estremi della serie storica, è possibile evidenziare quanto segue:

- **Fasi siccitose:** I picchi negativi di maggiore entità si sono registrati nel 1990 e nel 1996, con deficit precipitativi che hanno sfiorato il -30% rispetto alla norma. Un'altra anomalia negativa di forte entità si è verificata nel 2005 (circa -25%). Si notano inoltre periodi prolungati di sotto-media pluviometrica, come la sequenza consecutiva osservata tra il 2015 e il 2018.

- **Fasi di surplus pluviometrico:** L'anno che ha fatto registrare l'anomalia positiva più marcata è stato il 2014, superando il +40% rispetto alla media del periodo. Altre annate significativamente al di sopra della media di riferimento sono state il 2000 (circa +36%) e il 2002 (oltre +30%).

In conclusione, la serie storica analizzata è caratterizzata da forti e repentine fluttuazioni, con un'alternanza tra picchi di abbondanza idrica e fasi di grave deficit. Questa elevata variabilità interannuale rappresenta un parametro fondamentale di cui tenere conto per una corretta pianificazione e gestione delle risorse idriche del territorio.

L'istogramma evidenzia una distribuzione delle precipitazioni fortemente asimmetrica a destra. La stragrande maggioranza delle osservazioni si concentra infatti nella fascia 0-10 mm, come indicato dall'elevato picco di circa 14.000-15.000 conteggi. Oltre questa soglia, la frequenza degli eventi diminuisce drasticamente, indicando che le giornate con piogge intense sono rare.




**Figura 2.3:** Istogramma Precipitazioni Londra

## 2.2 Temperatura

### 2.2.1 Andamento delle temperature

Il grafico mostra le anomalie della temperatura media annuale rispetto al valore normale del periodo 1981-2010 (pari a  $11.3^{\circ}\text{C}$ ). A differenza delle precipitazioni, che mostravano forti sbalzi senza una direzione precisa, qui emerge una tendenza chiarissima e continua: le temperature stanno progressivamente aumentando.



**Figura 2.4:** Anomalia delle temperature annuali.


Osservando i colori delle barre, è molto facile dividere il periodo analizzato in due fasi distinte:

- **Prima del 2000:** Gli anni '80 e l'inizio degli anni '90 sono stati caratterizzati da temperature prevalentemente sotto la media (barre blu). In alcuni casi, il termometro è sceso anche di oltre 1 grado rispetto al valore di riferimento.
- **Dal 2000 in poi:** La situazione si inverte drasticamente. Quasi tutti gli anni registrano temperature sopra la media (barre arancioni e rosse). L'ultimo decennio è particolarmente significativo: le annate più calde in assoluto sono concentrate qui, con il 2014 e il 2020 che presentano anomalie termiche superiori a  $+1.3^{\circ}\text{C}$ .

Questo grafico fornisce una prova visiva molto evidente del riscaldamento climatico locale. Le annate calde, che un tempo rappresentavano un'eccezione, sono ormai diventate la nuova normalità.

### 2.2.2 Distribuzione stagionale e mensile delle temperature

Per comprendere a fondo il clima locale, è utile analizzare come le temperature si distribuiscono durante l'anno. Il primo grafico offre uno sguardo d'insieme sulle temperature **medie** stagionali.




**Figura 2.5**

Il grafico evidenzia il tipico ciclo annuale:

- **Inverno ed Estate:** Sono le stagioni con i valori più definiti. L'inverno si attesta su medie intorno ai 5°C (con rari picchi di freddo estremo sotto lo zero), mentre l'estate vede la maggior parte delle giornate con medie tra i 15°C e i 20°C.
- **Mezze stagioni:** Primavera e autunno mostrano una naturale maggiore variabilità (scatole più "alte"), fungendo da ponte tra il freddo invernale e il caldo estivo.

Se le medie stagionali ci danno il quadro generale, per valutare gli estremi di caldo è necessario fare uno "zoom". Il grafico seguente mostra infatti le temperature **massime** registrate mese per mese.



**Figura 2.6**

L'andamento segue la classica curva a campana, ma il dato più interessante è rappresentato dai punti esterni alle scatole (nella parte alta). Questi punti indicano le **ondate di calore**:

- Si nota chiaramente come, soprattutto tra **luglio e agosto**, si verifichino giornate eccezionalmente calde in cui le temperature massime si spingono ben oltre i 30°C, arrivando a sfiorare i 40°C.
- Questi eventi estremi, che le semplici medie stagionali tendevano a nascondere, sono fondamentali per comprendere il reale impatto del caldo sul territorio.

## 2.3 Relazione Tra Temperatura E Precipitazioni

Per comprendere meglio le dinamiche climatiche locali, è utile analizzare in quali condizioni termiche si verificano le maggiori precipitazioni. Il grafico a barre raggruppa le giornate in fasce di temperatura (dal freddo al caldo) e calcola per ciascuna la pioggia media.





Figura 2.7

Dall'analisi visiva del grafico emerge una chiara relazione non lineare tra i due parametri:

- **La fascia più piovosa (5°C - 15°C):** Le giornate in assoluto più ricche di precipitazioni sono quelle fresche o miti. In questa forbice di temperatura si registrano gli accumuli medi più elevati, vicini ai 2 mm al giorno.
- **Il calo con il caldo (> 15°C):** Man mano che le temperature salgono, la pioggia media diminuisce in modo drastico e costante. Le giornate calde (tra 25°C e 30°C) sono tendenzialmente asciutte, e le precipitazioni si azzerano quasi del tutto nelle giornate molto calde (oltre i 30°C).
- **Il freddo sotto zero (< 0°C):** Anche all'estremo opposto si nota un calo. Nelle giornate di gelo la precipitazione media è inferiore rispetto alle giornate miti, complice il fatto che l'aria molto fredda fatica a trattenere grandi quantità di umidità.

In sintesi, i dati confermano che le piogge più abbondanti si concentrano durante le tipiche giornate di mezza stagione o di inverno mite, mentre le ondate di caldo estivo coincidono in modo netto con i periodi di maggiore siccità.

Per approfondire ulteriormente questa dinamica, il grafico a dispersione (scatter plot) illustra la distribuzione di ogni singola giornata analizzata, incrociando la temperatura media, l'accumulo pluviometrico e il mese dell'anno (identificato dal colore).



**Figura 2.8:** Relazione tra Temperatura Media e Precipitazioni


Osservando attentamente la distribuzione e i colori dei singoli eventi estremi, emergono pattern stagionali ben definiti:

- **Autunno e fine estate (i picchi massimi):** Gli eventi giornalieri con i maggiori accumuli assoluti non si verificano nei mesi più freddi. Il picco massimo registrato (oltre 60 mm in 24 ore) è associato al mese di ottobre (punti arancioni). Anche agosto (verde chiaro) e settembre (giallo) mostrano eventi estremi superiori ai 40-50 mm.
- **L'intensità dei temporali estivi:** Nella porzione destra del grafico, in corrispondenza delle temperature più alte (sopra i 15-20°C), si nota la presenza di significativi eventi piovosi nei mesi centrali dell'estate, in particolare a luglio (punti rosa) e agosto (verde chiaro). Pur essendo giornate calde, possono generare accumuli giornalieri molto elevati (fino a 40 mm), tipici dei fenomeni temporaleschi estivi.
- **L'inverno con piogge frequenti ma moderate:** Spostandosi verso le temperature più rigide (tra 0°C e 10°C), si osserva un'altissima densità di giornate piovose nei mesi invernali come gennaio (punti blu) e febbraio (punti rossi). Tuttavia, in questi mesi l'accumulo giornaliero si mantiene quasi sempre al di sotto dei 20-30 mm.

In sintesi, il grafico rivela che le piogge invernali sono caratterizzate da un'alta frequenza ma da accumuli giornalieri moderati, mentre il rischio di precipitazioni estreme e abbondanti in singole giornate è decisamente più marcato tra la fine dell'estate e l'autunno.

## 2.4 Analisi Aggiuntive

Gli ultimi due grafici sono utili a capire le correlazioni tra le variabili presenti.



**Figura 2.9:** PairPlot variabili meteorologiche

- **Correlazioni positive evidenti tra temperature:** Nei pannelli tra `max_temp`, `mean_temp` e `min_temp`, i punti formano una nuvola lineare con pendenza positiva forte (es. `mean_temp` vs `max_temp`: i punti salgono da sinistra a destra). Questo indica che le temperature sono altamente correlate: quando la massima è alta, anche la media e la minima tendono a esserlo. La distribuzione è concentrata intorno a valori positivi, con code verso i valori estremi (freddi o caldi).
- **Radiazione globale e temperature:** Nei pannelli come `global_radiation` vs `max_temp` o `mean_temp`, c'è una correlazione positiva moderata (punti

che salgono con l'aumentare della radiazione). Ad esempio, radiazioni alte (300-400 W/m<sup>2</sup>) corrispondono a temperature più elevate (20-30°C), suggerendo un legame con l'esposizione solare.

- **Ore di sole e radiazione:** `Sunshine` vs `global_radiation` mostra una relazione positiva chiara: più ore di sole, più radiazione (punti allineati positivamente). Similmente, `sunshine` è negativamente correlato con `cloud_cover` (più nuvole, meno sole).
- **Precipitazioni e altre variabili:** `Precipitation` vs `temperature` mostra una correlazione debole o assente (punti sparsi, senza pattern lineare chiaro). Tuttavia, vs `snow_depth` c'è una leggera tendenza positiva in alcune regioni (più precipitazioni, più neve in periodi freddi). `Precipitation` ha valori alti in alcuni punti isolati, indicando eventi estremi.
- **Pressione e temperature:** `Pressure` vs `mean_temp` mostra una correlazione negativa debole (punti leggermente discendenti): pressioni alte tendono a coincidere con temperature più basse.
- **Neve e temperature:** `Snow_depth` vs `temperature` (`max_temp`/`mean_temp`/`min_temp`) mostra una correlazione negativa forte: profondità neve alta solo a temperature basse (sotto 0°C), con punti concentrati vicino allo zero per temperature positive.
- **Variabili temporali:** `Day` vs `year` mostra punti sparsi, forse indicando dati su più anni senza pattern forte. `Year` vs altre variabili (es. vs `temperature`) potrebbe mostrare trend temporali, ma i punti sono diffusi, suggerendo variabilità stagionale più che trend annuali.
- **Distribuzioni univariate (diagonale):** Gli istogrammi mostrano che molte variabili sono unimodali (es. `mean_temp` centrata intorno a 10-15°C), mentre `precipitation` e `snow_depth` sono sbilanciate verso zero (pochi eventi estremi). `Cloud_cover` e `pressure` sono più uniformi.

Il pairplot rivela pattern stagionali tipici: temperature e radiazione solare sono legate al ciclo solare (sole/nuove), mentre precipitazioni e neve sono più variabili e legate al freddo. Non ci sono outlier estremi evidenti, ma la densità dei punti indica che i dati sono concentrati in regimi "normali" meteorologici. Questo grafico è utile per identificare coppie di variabili correlate da esplorare ulteriormente (es. per modelli di regressione). Possiamo notare una correlazione importante tra le temperature massime, minime e medie. Così come tra i giorni nuvolosi e le giornate soleggiate.

La figura 2.10 rappresenta una heatmap che visualizza i coefficienti di correlazione di Pearson (valori da -1 a 1) tra le stesse variabili. I colori indicano la forza: blu scuro per correlazioni negative forti, rosso per positive forti, bianco/grigio per deboli o nulle. La scala va da -1 (blu) a 1 (rosso), con valori numerici annotati nelle celle.




Figura 2.10: HeatMap variabili meteorologiche

## Capitolo 3

# Classificazione

---

In questo capitolo viene applicata la classificazione binaria, tecnica fondamentale dell'apprendimento automatico supervisionato, con l'obiettivo di predire la presenza o l'assenza di precipitazioni giornaliere a Londra sulla base delle variabili meteorologiche disponibili.

### 3.1 Pre-processing dei dati

---

La fase iniziale ha previsto una preparazione accurata dei dati attraverso operazioni di *pre-processing*, fondamentali per ottenere risultati significativi e affidabili.

Il dataset utilizzato, `london_weather.csv`, contiene osservazioni meteorologiche giornaliere di Londra dal 1979 al 2020, con le seguenti colonne: *date*, *cloud\_cover*, *sunshine*, *global\_radiation*, *max\_temp*, *mean\_temp*, *min\_temp*, *precipitation*, *pressure* e *snow\_depth*.

#### 3.1.1 Gestione dei valori mancanti

I valori mancanti presenti nelle colonne numeriche sono stati sostituiti con la media della rispettiva colonna tramite il metodo `fillna()`. Questo approccio preserva l'integrità del dataset evitando la perdita di osservazioni.

#### 3.1.2 Feature engineering

Per catturare la dipendenza temporale delle precipitazioni — caratteristica essenziale nei dati meteorologici sequenziali — sono state introdotte feature basate esclusivamente su informazioni passate (*lag*):

- `precip_lag1`: precipitazione del giorno precedente ( $t - 1$ );
- `precip_ma3`: media mobile calcolata sui tre giorni precedenti ( $t - 1$ ,  $t - 2$ ,  $t - 3$ ), ottenuta applicando `shift(1)` prima del rolling per escludere il giorno corrente ed evitare *data leakage*;
- `sunshine_lag1`: ore di sole del giorno precedente;

- `cloud_lag1`: copertura nuvolosa del giorno precedente;
- variabili dummy per il mese (`month_1-month_12`), ottenute con `pd.get_dummies`, per modellare la stagionalità;
- la variabile `day` per rappresentare l'andamento infrasettimanale.

Tutte le feature di lag utilizzano esclusivamente dati già noti al momento della previsione, rispettando il principio di causalità temporale. Il *MinMaxScaler* è stato inserito all'interno delle pipeline di modellazione (e non applicato globalmente a priori), in modo da adattarsi esclusivamente ai dati di training di ciascun fold, prevenendo ogni forma di contaminazione con il set di validazione.


### 3.1.3 Creazione del target binario

Il target binario  $y$  è stato definito mediante una soglia automatica pari al 60° percentile della precipitazione giornaliera, che corrisponde a 0.2 mm. Ciò produce una distribuzione realistica di circa 60% di giorni senza pioggia e 40% con pioggia:

$$y = \begin{cases} 0 & \text{se precipitation} \leq 0.2 \text{ mm} \quad (\text{no pioggia}) \\ 1 & \text{se precipitation} > 0.2 \text{ mm} \quad (\text{pioggia}) \end{cases}$$


### 3.1.4 Riduzione della multicollinearità

La heatmap di correlazione in Figura 3.1 rivela correlazioni molto elevate tra `max_temp`, `mean_temp`, `min_temp` e `global_radiation`. Queste variabili sono state rimosse dal set di feature per evitare multicollinearità, che può destabilizzare i modelli lineari e ridurre l'interpretabilità dei coefficienti.



**Figura 3.1:** Heatmap delle correlazioni tra tutte le variabili numeriche originali e il target  $y$ . La riga  $y$  mostra il potere predittivo iniziale di ciascuna variabile: correlazione negativa con `sunshine` e positiva con `cloud_cover`, coerenti con le attese fisiche.

La Figura 3.2 mostra la heatmap dopo la rimozione delle variabili ridondanti. L'assenza di correlazioni prossime a  $\pm 1.0$  (eccetto la diagonale) conferma che il set finale di 21 feature è pulito e caratterizzato da bassa multicollinearità.



**Figura 3.2:** Heatmap dopo la rimozione di `max_temp`, `mean_temp`, `min_temp` e `global_radiation`.

### 3.1.5 Split temporale e gestione dello sbilanciamento

Il dataset è stato diviso rispettando la sequenzialità temporale:

- **Training set:** osservazioni dal 1979 al 2018 (14.610 campioni);
- **Test set:** anni 2019–2020 (731 campioni).

Uno split casuale avrebbe permesso al modello di “vedere il futuro” durante il training, producendo stime di performance irrealisticamente ottimistiche.

Per gestire lo sbilanciamento 60/40, al posto di tecniche di sovracampionamento sintetico (come SMOTE, sconsigliato con sbilanciamenti moderati), si è adottata la parametrizzazione `class_weight='balanced'` per Logistic Regression, Decision Tree, Random Forest e SVC, e `scale_pos_weight` (rapporto neg/pos sul training set) per XGBoost. Entrambi i meccanismi aumentano il peso degli errori sulla classe minoritaria durante il training, senza alterare la distribuzione originaria dei dati.

## 3.2 Training dei dati

Sono stati selezionati cinque algoritmi rappresentativi di diverse famiglie di modelli, ciascuno inserito in una pipeline `MinMaxScaler + Classificatore`:

- **Logistic Regression** (`solver='liblinear'`, `class_weight='balanced'`): modello lineare, rapido e interpretabile, utile come baseline;

- **Decision Tree** (`class_weight='balanced'`): albero decisionale, massima interpretabilità ma tendenza all'overfitting;
- **Random Forest** (100 alberi, `class_weight='balanced'`): ensemble di alberi che riduce la varianza tramite averaging;
- **XGBoost** (`scale_pos_weight` calibrato): gradient boosting ottimizzato, forte su dati tabulari;
- **SVC** (`probability=True`, `class_weight='balanced'`): classificatore a margine massimo, efficace con dati normalizzati.

La cross-validazione è stata eseguita con `TimeSeriesSplit` a 5 fold, che preserva l'ordine cronologico: in ogni fold, i dati di validazione sono sempre successivi a quelli di training.


### 3.3 Risultati della Classificazione

La Tabella 3.1 riassume i punteggi medi di F1-weighted in cross-validazione e l'accuratezza sul test set per ciascun modello. La Figura 3.3 visualizza il confronto tramite barplot con barre di errore pari alla deviazione standard.

| Classificatore      | F1-weighted CV (5 fold) | Accuratezza Test |
|---------------------|-------------------------|------------------|
| Logistic Regression | $0.7417 \pm 0.0122$     | 0.7661           |
| SVC                 | $0.7410 \pm 0.0105$     | 0.7702           |
| Random Forest       | $0.7409 \pm 0.0114$     | 0.7579           |
| XGBoost             | $0.7213 \pm 0.0092$     | 0.7387           |
| Decision Tree       | $0.6696 \pm 0.0084$     | 0.6484           |


**Tabella 3.1:** F1-weighted in cross-validazione temporale (5 fold) e accuratezza sul test set (731 campioni, anni 2019–2020).

I tre modelli migliori in cross-validazione — Logistic Regression, SVC e Random Forest — raggiungono F1-weighted compresi tra 0.740 e 0.742, con deviazioni standard contenute (0.011–0.012), indicando stabilità nelle stime. SVC ottiene la migliore accuratezza sul test set (77.0%). XGBoost registra un lieve calo in CV (0.721), mentre il Decision Tree singolo è il meno performante (CV 0.670), confermando la sua tendenza all'overfitting senza potatura.



**Figura 3.3:** Barplot dei punteggi F1-weighted in cross-validazione temporale (TimeSeriesSplit, 5 fold). Le barre di errore rappresentano la deviazione standard.

Le matrici di confusione sul test set sono riportate in Figura 3.4. Si osserva che i modelli lineari (Logistic Regression, SVC) tendono a favorire il recall della classe positiva (pioggia), mentre Random Forest privilegia la precisione sulla classe negativa.



**Figura 3.4:** Matrici di confusione per tutti e cinque i classificatori sul test set. Righe: valori reali; colonne: predizioni.

### 3.4 Metriche dettagliate per classificatore

Di seguito si riportano i classification report ottenuti sul test set (classe 0 = no pioggia, 424 campioni; classe 1 = pioggia, 307 campioni).

### Logistic Regression

| Classe       | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0 (No Rain)  | 0.84      | 0.74   | 0.79     | 424     |
| 1 (Rain)     | 0.69      | 0.80   | 0.74     | 307     |
| Accuracy     | 0.77      |        |          |         |
| Macro avg    | 0.76      | 0.77   | 0.76     | 731     |
| Weighted avg | 0.78      | 0.77   | 0.77     | 731     |

### Decision Tree Classifier

| Classe       | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0 (No Rain)  | 0.69      | 0.70   | 0.70     | 424     |
| 1 (Rain)     | 0.58      | 0.57   | 0.58     | 307     |
| Accuracy     | 0.65      |        |          |         |
| Macro avg    | 0.64      | 0.64   | 0.64     | 731     |
| Weighted avg | 0.65      | 0.65   | 0.65     | 731     |

### Random Forest Classifier

| Classe       | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0 (No Rain)  | 0.77      | 0.82   | 0.80     | 424     |
| 1 (Rain)     | 0.73      | 0.67   | 0.70     | 307     |
| Accuracy     | 0.76      |        |          |         |
| Macro avg    | 0.75      | 0.75   | 0.75     | 731     |
| Weighted avg | 0.76      | 0.76   | 0.76     | 731     |

### XGBoost Classifier

| Classe       | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0 (No Rain)  | 0.79      | 0.75   | 0.77     | 424     |
| 1 (Rain)     | 0.68      | 0.72   | 0.70     | 307     |
| Accuracy     | 0.74      |        |          |         |
| Macro avg    | 0.73      | 0.74   | 0.73     | 731     |
| Weighted avg | 0.74      | 0.74   | 0.74     | 731     |


### Support Vector Classifier (SVC)

| Classe       | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0 (No Rain)  | 0.83      | 0.75   | 0.79     | 424     |
| 1 (Rain)     | 0.70      | 0.79   | 0.74     | 307     |
| Accuracy     | 0.77      |        |          |         |
| Macro avg    | 0.77      | 0.77   | 0.77     | 731     |
| Weighted avg | 0.78      | 0.77   | 0.77     | 731     |

Dalla lettura comparata dei report emerge un pattern comune: tutti i modelli raggiungono recall più elevato sulla classe positiva (pioggia) rispetto alla precision, effetto atteso del bilanciamento via `class_weight`. Random Forest fa eccezione, privilegiando precision (0.73) a scapito del recall (0.67) sulla classe 1.

### 3.5 Curve ROC

La Figura 3.5 mostra le curve ROC di tutti i modelli sul test set. L'area sotto la curva (AUC) quantifica la capacità del modello di discriminare tra le due classi indipendentemente dalla soglia scelta. Logistic Regression e SVC ottengono i valori più alti ( $AUC \approx 0.85$ ), seguiti da Random Forest e XGBoost ( $AUC \approx 0.84$ ); il Decision Tree si ferma a 0.77, confermando le indicazioni già emerse dai classification report.



**Figura 3.5:** Curve ROC per i cinque classificatori sul test set. La diagonale tratteggiata rappresenta un classificatore casuale ( $AUC = 0.5$ ).

### 3.6 Ottimizzazione degli Iperparametri con Grid Search

I due modelli ensemble più promettenti — **Random Forest** e **XGBoost** — sono stati sottoposti a ricerca degli iperparametri ottimali tramite `GridSearchCV`. Anche in questa fase è stata utilizzata una pipeline `MinMaxScaler + Classifier` con `TimeSeriesSplit` a 3 fold (ridotto per contenere i tempi computazionali) e F1-weighted come metrica.

```
1  'RandomForest': {
2      'classifier__n_estimators': [50, 100],
3      'classifier__max_depth': [5, 8, None],
4      'classifier__min_samples_split': [2, 5]
5  }
```

**Listing 3.1:** Griglia degli iperparametri – Random Forest

```
1  'XGBoost': {
2      'classifier__n_estimators': [100, 200],
3      'classifier__max_depth': [3, 6],
4      'classifier__learning_rate': [0.01, 0.1]
5  }
```

**Listing 3.2:** Griglia degli iperparametri – XGBoost

I migliori iperparametri individuati e i relativi punteggi sono riportati in Tabella 3.2.


| Modello       | Migliori parametri                                       | F1-weighted CV |
|---------------|----------------------------------------------------------|----------------|
| Random Forest | n_estimators=100, max_depth=None,<br>min_samples_split=5 | 0.7449         |
| XGBoost       | n_estimators=200, max_depth=3,<br>learning_rate=0.1      | 0.7436         |

**Tabella 3.2:** Risultati della Grid Search: migliori iperparametri e punteggio F1-weighted in cross-validazione temporale (3 fold).

L’ottimizzazione ha prodotto un miglioramento per entrambi i modelli rispetto ai valori di default: Random Forest passa da 0.7409 a 0.7449 (+0.004), XGBoost da 0.7213 a 0.7436 (+0.022), con un guadagno particolarmente significativo per quest’ultimo.

### 3.7 Matrice di correlazione tra le predizioni

Prima di costruire l’ensemble, è stata analizzata la correlazione tra le predizioni dei cinque classificatori sul test set (Figura 3.6). Correlazioni elevate indicano che i modelli commettono errori simili; correlazioni basse segnalano complementarità e motivano la costruzione di un ensemble. Random Forest e XGBoost mostrano la correlazione più bassa tra le coppie di modelli considerati, rendendoli candidati ideali per il Voting Classifier.



**Figura 3.6:** Matrice di correlazione tra le predizioni dei cinque classificatori sul test set.

### 3.8 Modello ensemble: Voting Classifier

Sulla base dei risultati della Grid Search e dell'analisi di correlazione tra le predizioni, è stato costruito un **Voting Classifier** di tipo *soft voting*, che combina le probabilità stimate da **Random Forest** e **XGBoost** ottimizzati. Nel soft voting la classe predetta è quella con la probabilità media più alta tra i sub-modelli, sfruttando la complementarità delle loro distribuzioni di errore. Il modello è stato addestrato sull'intero training set (fino al 2018) e valutato sul test set (2019–2020).

#### 3.8.1 Risultati con soglia predefinita (0.5)

Con la soglia di default 0.5, il Voting Classifier ottiene:


- **Accuracy:** 0.7551
- **F1-score macro:** 0.7503
- **F1-score weighted:** 0.7558

Il classification report dettagliato è riportato in Tabella 3.3.

| Classe       | Precision | Recall | F1-score | Supporto |
|--------------|-----------|--------|----------|----------|
| 0 (No Rain)  | 0.80      | 0.77   | 0.79     | 424      |
| 1 (Rain)     | 0.70      | 0.73   | 0.72     | 307      |
| Macro avg    | 0.75      | 0.75   | 0.75     | 731      |
| Weighted avg | 0.76      | 0.76   | 0.76     | 731      |

**Tabella 3.3:** Classification Report del Voting Classifier (soglia 0.5).

La matrice di confusione con soglia 0.5 è mostrata in Figura 3.7.



**Figura 3.7:** Matrice di confusione del Voting Classifier con soglia 0.5.

### 3.8.2 Ottimizzazione della soglia di classificazione

La soglia di default 0.5 non è necessariamente ottimale: abbassandola si aumenta il recall della classe positiva (meno falsi negativi) a scapito della precision (più falsi positivi). Tramite la curva Precision-Recall è stata individuata la soglia che massimizza l’F1-score sul test set:

- **Soglia 0.5:** F1-score = 0.7154
- **Soglia ottimale (0.377):** F1-score = 0.7556 (+0.040)


Il classification report con soglia ottimale è presentato in Tabella 3.4.

| Classe       | Precision | Recall | F1-score | Supporto |
|--------------|-----------|--------|----------|----------|
| 0 (No Rain)  | 0.88      | 0.68   | 0.77     | 424      |
| 1 (Rain)     | 0.66      | 0.88   | 0.76     | 307      |
| Macro avg    | 0.77      | 0.78   | 0.76     | 731      |
| Weighted avg | 0.79      | 0.76   | 0.76     | 731      |

**Tabella 3.4:** Classification Report del Voting Classifier con soglia ottimale (0.377).

Rispetto alla soglia 0.5, il recall sulla classe pioggia passa da 0.73 a 0.88 (+0.15), mentre la precision scende da 0.70 a 0.66 (−0.04). Questo trade-off è vantaggioso


nei contesti in cui un falso negativo (giorno di pioggia non rilevato) è più costoso di un falso positivo. Il confronto tra le due matrici di confusione è mostrato in Figura 3.8.




**Figura 3.8:** Confronto delle matrici di confusione: soglia 0.5 (sinistra) vs soglia ottimale 0.377 (destra).

### 3.8.3 Curva ROC e Precision-Recall

La curva ROC del Voting Classifier (Figura 3.9) mostra un'AUC di circa 0.89, superiore a quella dei singoli modelli componenti (RF  $\approx$  0.84, XGBoost  $\approx$  0.84), confermando il beneficio dell'ensemble. La curva Precision-Recall (Figura 3.10) evidenzia che il modello mantiene una precision accettabile anche per valori elevati di recall, con una precisione media (*average precision*) prossima a 0.88.




**Figura 3.9:** Curva ROC del Voting Classifier ottimizzato (AUC  $\approx$  0.89).




**Figura 3.10:** Curva Precision-Recall del Voting Classifier.

### 3.8.4 Learning Curve

Le Figure 3.11 e 3.12 mostrano le learning curve del Voting Classifier, ottenute rispettivamente con Yellowbrick (TimeSeriesSplit, 5 fold) e con scikit-learn (TimeSeriesSplit, 3 fold, con bande di deviazione standard).



**Figura 3.11:** Learning Curve con Yellowbrick (TimeSeriesSplit, 5 fold).



**Figura 3.12:** Learning Curve con scikit-learn (bande = deviazione standard).

Entrambe le curve mostrano un training score stabile intorno a 0.88 e un cross-validation score che cresce rapidamente e converge attorno a 0.80. Il divario residuo di circa 0.08 punti indica un lieve overfitting, fisiologico per un modello ensemble complesso. La convergenza delle curve al crescere dei dati di training esclude tuttavia un fenomeno di overfitting marcato e suggerisce una buona capacità di generalizzazione.

### 3.9 Conclusioni sulla classificazione

L'analisi di classificazione binaria delle precipitazioni giornaliere ha prodotto i seguenti risultati principali:

- **Migliori modelli individuali:** Logistic Regression, SVC e Random Forest raggiungono F1-weighted  $\approx 0.74$  in cross-validazione e accuratezza del 75–77% sul test set, con SVC al primo posto (77.0%).
- **Ruolo del feature engineering:** le feature di lag (`precip_lag1`, `precip_ma3`, `sunshine_lag1`, `cloud_lag1`) si sono rivelate fondamentali per catturare la dipendenza temporale delle precipitazioni senza introdurre data leakage.
- **Grid Search:** l'ottimizzazione ha migliorato XGBoost di 0.022 punti di F1, rendendolo competitivo con Random Forest.
- **Voting Classifier:** la combinazione di RF e XGBoost ottimizzati in un ensemble soft voting produce AUC = 0.89, superiore ai singoli componenti.
- **Ottimizzazione della soglia:** abbassare la soglia da 0.5 a 0.377 aumenta il recall sulla classe pioggia da 0.73 a 0.88, riducendo i falsi negativi a favore di una maggiore sensibilità al fenomeno d'interesse.

La metodologia adottata — split temporale, feature esclusivamente causali, scaling interno alle pipeline, bilanciamento tramite `class_weight` senza sovra-campionamento — garantisce l'affidabilità dei risultati e la loro applicabilità in un contesto previsionale reale.

## Capitolo 4

# Clustering

---

In questo capitolo si introduce il clustering, un metodo di apprendimento non supervisionato che ha lo scopo di suddividere un insieme di dati in gruppi omogenei, detti cluster, basandosi sulla somiglianza tra i punti all'interno di ciascun gruppo.

Per garantire l'efficacia degli algoritmi, è stata eseguita una serie di operazioni preliminari sul dataset. In primo luogo, sono stati gestiti i valori mancanti nelle colonne numeriche (come `cloud_cover`, `sunshine`, `max_temp`, ecc.) sostituendoli con la media della rispettiva colonna tramite il metodo `fillna()`. Successivamente, per uniformare la scala delle variabili, è stata applicata la standardizzazione con `StandardScaler` di scikit-learn, un passaggio cruciale per algoritmi sensibili alla scala come K-Means e DBSCAN. Infine, la colonna `date` è stata convertita nel formato `datetime` per permettere le analisi di tipo temporale.


### 4.1 Clustering delle Temperature

---

In questa sezione, il clustering è stato applicato alle variabili di temperatura (`max_temp`, `mean_temp` e `min_temp`) per ottenere una rappresentazione completa delle condizioni termiche. L'obiettivo è identificare gruppi di giornate con profili di temperatura simili.


Il primo algoritmo utilizzato è il K-Means, che raggruppa i dati in un numero  $k$  di cluster minimizzando la varianza interna a ciascun cluster. Per determinare il numero ottimale di cluster, sono state impiegate due tecniche principali:

- **Il Metodo del Gomito (Elbow Method):** analizza la somma dei quadrati della varianza intra-cluster (WCSS) al variare di  $k$ . Il numero ottimale di cluster si trova nel "gomito", ovvero il punto in cui l'aggiunta di un nuovo cluster non porta più a una riduzione significativa della WCSS.
- **Il Punteggio di Silhouette:** misura la qualità del clustering valutando quanto ogni punto sia simile al proprio cluster (coesione) rispetto ai cluster vicini (separazione). Un punteggio più alto indica cluster meglio definiti.



**Figura 4.1:** Metodo Elbow per il clustering delle Temperature.

La curva WCSS (Figura 4.1) mostra una forte diminuzione fino a  $k = 4$ , dopodiché l'aggiunta di ulteriori cluster produce solo modesti miglioramenti. Il gomito più evidente si colloca quindi a  $k = 4$ .




**Figura 4.2**

Il Silhouette Score (Figura 4.2) raggiunge il massimo per  $k = 2$  (circa 0.53), ma la scelta di  $k = 4$  è supportata dal metodo Elbow e da una migliore interpretabilità dei regimi termici. Con  $k = 4$  il Silhouette Score scende a 0.3825, indicando una separazione moderata e una certa sovrapposizione tra regimi termici contigui, aspetto fisiologico quando si vogliono distinguere più di due sole condizioni (freddo/caldo).

#### 4.1.1 K-Means Clustering

Applicando K-Means con  $k = 4$  ai dati standardizzati si ottengono i cluster visualizzati in Figura 4.3, nello spazio delle prime due variabili standardizzate ( $\text{max\_temp}$  e  $\text{mean\_temp}$ ).



**Figura 4.3:** K-Means Clustering delle Temperature ( $\text{max\_temp}$  e  $\text{mean\_temp}$  standardizzate).


I centroidi in scala originale sono riportati nella Tabella 4.1. Sulla base di essi, i quattro cluster possono essere descritti come:

1. **Molto Freddo** (colore blu scuro): temperature molto basse (media  $3.6^{\circ}\text{C}$ ), tipiche del pieno inverno.
2. **Freddo Transizione** (colore viola): condizioni di passaggio tra l'inverno e le mezze stagioni (media  $8.9^{\circ}\text{C}$ ).
3. **Fresco/Mite** (colore oro): temperature primaverili o autunnali (media  $14.1^{\circ}\text{C}$ ).
4. **Caldo** (colore rosso): temperature elevate estive (media  $19.1^{\circ}\text{C}$ ); è il cluster più compatto e isolato.

**Tabella 4.1:** Centroidi dei cluster di temperatura in scala originale (°C).

| Regime             | max_temp | mean_temp | min_temp |
|--------------------|----------|-----------|----------|
| Molto Freddo       | 7.3      | 3.6       | 0.2      |
| Freddo Transizione | 12.2     | 8.9       | 5.5      |
| Fresco/Mite        | 18.1     | 14.0      | 10.0     |
| Caldo              | 23.9     | 19.1      | 14.2     |

Il Silhouette Plot (Figura 4.4) evidenzia che il cluster Caldo ha la massima coesione, con un'ampia lama che supera la media (0.38), mentre i regimi più freddi e di transizione presentano una maggiore variabilità interna e qualche punto con silhouette negativa, segno di possibili assegnazioni incerte.

**Figura 4.4:** Silhouette Plot per K-Means sulle temperature ( $k = 4$ ).

#### 4.1.2 Validazione e confronto con Clustering Gerarchico

La qualità del raggruppamento è stata quantificata con l'indice di Silhouette e il Davies-Bouldin Score:

- **K-Means:** Silhouette = 0.3825, Davies-Bouldin = 0.8281.
- **Agglomerative (Ward):** Silhouette = 0.3478, Davies-Bouldin = 0.8589.

L'algoritmo gerarchico (Figura 4.5) produce una segmentazione simile, con i quattro regimi termici disposti nello stesso ordine. Le metriche quasi identiche confermano che la struttura a quattro cluster è robusta, pur con una separazione non netta tra regimi adiacenti.




Figura 4.5

## 4.2 Clustering su Radiazione Solare e Precipitazioni

Per questo secondo raggruppamento sono state considerate le variabili `global_radiation` e `precipitation`. L'analisi preliminare con il metodo Elbow (Figura 4.6) e il Silhouette Score (Figura 4.7) indica all'unanimità  $k = 4$  come numero ottimale di cluster.




Figura 4.6: Metodo del Gomito per Radiazione e Precipitazioni.




Figura 4.7

Il Silhouette Score per  $k = 4$  è 0.5526, un valore nettamente superiore a quello ottenuto per le temperature, indice di cluster ben separati e coesi.

#### 4.2.1 Risultati del K-Means

I centroidi in unità originali e le statistiche descrittive di ciascun cluster sono riportati nelle Tabelle 4.2 e 4.3.

**Tabella 4.2:** Centroidi dei cluster per radiazione e precipitazioni.


| Regime            | global_radiation (W/m <sup>2</sup> ) | precipitation (mm) |
|-------------------|--------------------------------------|--------------------|
| Secco/Soleggiato  | 224.8                                | 0.44               |
| Asciutto/Nuvoloso | 62.5                                 | 0.61               |
| Piovoso/Nuvoloso  | 73.6                                 | 7.49               |
| Molto Piovoso     | 82.6                                 | 21.14              |

**Tabella 4.3:** Statistiche descrittive medie ( $\mu \pm \sigma$ ) per ciascun regime di radiazione e precipitazioni.

| Regime            | Radiazione (W/m <sup>2</sup> ) | Precipitazione (mm) | Giorni |
|-------------------|--------------------------------|---------------------|--------|
| Secco/Soleggiato  | 224.8 $\pm$ 52.4               | 0.44 $\pm$ 1.09     | 5 168  |
| Asciutto/Nuvoloso | 62.5 $\pm$ 38.5                | 0.61 $\pm$ 1.01     | 8 198  |
| Piovoso/Nuvoloso  | 73.6 $\pm$ 58.4                | 7.50 $\pm$ 2.64     | 1 717  |
| Molto Piovoso     | 82.6 $\pm$ 63.5                | 21.14 $\pm$ 7.56    | 258    |


Dai dati emergono quattro regimi meteorologici ben distinti:

1. **Secco/Soleggiato**: radiazione elevata e precipitazioni quasi assenti. Comprende 5 168 giorni.
2. **Asciutto/Nuvoloso**: bassa radiazione e precipitazioni minime; è il cluster più numeroso (8 198 giorni), tipico del tempo grigio ma asciutto.
3. **Piovoso/Nuvoloso**: precipitazioni moderate (7.5 mm in media) e radiazione bassa/media; 1 717 giorni.
4. **Molto Piovoso**: precipitazioni intense (21.1 mm in media), radiazione bassa/media; solo 258 giorni, gli eventi più estremi.



**Figura 4.8:** K-Means Clustering: Precipitazioni vs Radiazione Solare ( $k = 4$ ).


Il Silhouette Plot (Figura 4.9) mostra una lama molto estesa per il cluster Secco/Soleggiato, che risulta il più coeso. Gli altri regimi sono comunque ben sopra la media, senza code negative significative.



**Figura 4.9:** Silhouette Plot per K-Means su Radiazione e Precipitazioni.

#### 4.2.2 Confronto con il Clustering Gerarchico

L'Agglomerative Clustering con linkage di Ward (Figura 4.10) restituisce una struttura analoga, con metriche quasi identiche: Silhouette 0.5360 e Davies-Bouldin 0.7053, a conferma della solidità della suddivisione in quattro regimi.




**Figura 4.10:** Clustering Gerarchico Agglomerativo: Precipitazioni vs Radiazione Solare.

### 4.3 Analisi con PCA e DBSCAN

#### 4.3.1 Riduzione dimensionale e K-Means su PCA


L'applicazione della PCA alle variabili standardizzate produce due componenti principali che spiegano il 100% della varianza (dato che le variabili originali sono solo due). La visualizzazione dei cluster K-Means nello spazio PCA (Figura 4.11) mostra che la struttura a quattro regimi viene preservata e i centroidi sono ben posizionati.



**Figura 4.11:** Cluster K-Means nello spazio delle componenti principali.


#### 4.3.2 DBSCAN

Per esplorare la densità locale, è stato applicato DBSCAN. Il parametro  $\epsilon$  è stato scelto mediante il grafico delle distanze al secondo vicino più prossimo (Figura 4.12), che evidenzia un ginocchio intorno a 0.5.



**Figura 4.12:** Grafico delle distanze per la scelta di  $\epsilon$ .

Con  $\varepsilon = 0.5$  e `min_samples=5`, DBSCAN identifica 3 cluster densi e classifica 19 punti come rumore (Figura 4.13). Ciò indica che la maggioranza delle giornate non appartiene a regioni a densità sufficientemente elevata per DBSCAN, ma i tre raggruppamenti trovati corrispondono a condizioni specifiche (tipicamente giorni molto secchi/soleggiati, giorni con precipitazioni moderate e giorni con precipitazioni estreme). Questo risultato è coerente con l'analisi K-Means e aggiunge l'informazione che la nuvola di punti ha una densità fortemente eterogenea.



**Figura 4.13:** Cluster DBSCAN visualizzati sulle componenti principali.

#### 4.4 Conclusioni del Clustering

L'analisi di clustering ha permesso di segmentare le oltre 15 000 giornate in regimi climatici interpretabili:

- **Temperature:** quattro regimi termici (Molto Freddo, Freddo di Transizione, Fresco/Mite, Caldo) descrivono efficacemente le condizioni termiche, con un Silhouette moderato (0.38) che riflette una fisiologica sovrapposizione tra regimi adiacenti.
- **Radiazione e precipitazioni:** quattro regimi atmosferici (Secco/Soleggiato, Asciutto/Nuvoloso, Piovoso/Nuvoloso, Molto Piovoso) emergono con un'ottima qualità (Silhouette  $\approx 0.55$ ) e sono confermati sia da K-Means che dal gerarchico.
- L'analisi con DBSCAN rivela che solo una piccola parte dei dati forma cluster densi: la maggioranza delle giornate presenta caratteristiche meno estreme e quindi non viene raggruppata, coerentemente con la natura variabile del clima londinese.

La metodologia adottata – standardizzazione, validazione con metriche, confronto tra algoritmi partizionali e gerarchici, e approfondimento con PCA e DBSCAN – fornisce una visione solida e sfaccettata della struttura latente dei dati meteorologici.

## Capitolo 5

# Analisi Temporale


---

In questo capitolo verranno applicati modelli statistici per l'analisi e la previsione delle precipitazioni giornaliere a Londra. L'obiettivo è identificare pattern temporali, tendenze e stagionalità, e valutare la capacità predittiva di modelli ARIMA e SARIMAX.


### 5.1 Preparazione dei dati e stazionarietà

---


Dopo le operazioni di pre-processing (gestione dei valori mancanti e conversione della data in formato datetime), la serie storica delle precipitazioni giornaliere è stata esaminata preliminarmente attraverso il suo andamento generale (Figure 5.1, 5.2 e 5.3).



**Figura 5.1:** Andamento generale delle precipitazioni (1979-2020).



**Figura 5.2:** Precipitazioni giornaliere nel periodo 2016-2020.



**Figura 5.3:** Precipitazioni giornaliere nell'anno 2020.


Successivamente, per verificare la stazionarietà della serie è stato eseguito il test di Dickey-Fuller aumentato (ADF). I risultati sono riportati di seguito:

- **ADF Statistic:**  $-40.0137$
- **p-value:**  $< 0.05$
- **Valori critici:**
  - 1%:  $-3.430$
  - 5%:  $-2.862$
  - 10%:  $-2.567$


Poiché il valore della statistica ADF è ampiamente inferiore a tutte le soglie critiche e il p-value è praticamente nullo, si rifiuta con elevata confidenza l'ipotesi nulla di presenza di una radice unitaria: la serie è stazionaria e non necessita di differenziazione ( $d = 0$ ).

## 5.2 Scelta dei parametri $p$ e $q$

Per determinare l'ordine dei termini autoregressivi ( $p$ ) e a media mobile ( $q$ ) sono stati analizzati i grafici di autocorrelazione (ACF) e autocorrelazione parziale (PACF), riportati nelle Figure 5.4 e 5.5. Entrambi mostrano un decadimento rapido dopo il primo ritardo, suggerendo che un modello semplice con  $p = 1$  e  $q = 1$  può essere adeguato. Come termine di confronto è stato inoltre considerato un modello con  $q = 2$ .




**Figura 5.4:** Autocorrelazione (ACF) della serie delle precipitazioni.



**Figura 5.5:** Autocorrelazione parziale (PACF) della serie delle precipitazioni.

La funzione `seasonal_decompose` della libreria `statsmodels` consente inoltre di scomporre la serie nelle componenti trend, stagionale e residua, evidenziando la presenza di una componente stagionale annuale (Figura 5.6).




**Figura 5.6:** Decomposizione stagionale della serie delle precipitazioni.

### 5.3 Modelli ARIMA

Sono stati addestrati due modelli ARIMA sull'intera serie storica:


- ARIMA(1,0,1)
- ARIMA(1,0,2)

L'analisi dei residui del modello ARIMA(1,0,1) (Figura 5.7) mostra che essi non presentano pattern evidenti e si distribuiscono simmetricamente attorno allo zero, come si evince dal grafico di densità. Ciò indica un buon adattamento del modello.



**Figura 5.7:** Residui del modello ARIMA(1,0,1).


La previsione per i 375 giorni successivi all'ultima data disponibile (circa un anno) è mostrata in Figura 5.8. Dopo una breve fase transitoria, la previsione si assesta su un valore costante, pari al livello medio della serie, a causa della semplicità del modello e della stazionarietà della serie stessa.



**Figura 5.8:** Previsione con ARIMA(1,0,1) per l’anno 2021.

5.4 Validazione out-of-time

Per valutare la reale capacità previsionale del modello, è stata condotta una validazione out-of-time: l’85% dei dati (fino al 2015) è stato utilizzato come training set, mentre il restante 15% (2016–2020) ha costituito il test set. Un nuovo modello ARIMA(1,0,1) è stato addestrato sui soli dati di training e le previsioni sono state confrontate con i valori reali (Figura 5.9). Le metriche di errore sono riassunte nella Tabella 5.1.



**Figura 5.9:** Validazione out-of-time: training (blu), valori reali (arancione) e previsioni (verde) con intervallo di confidenza.

**Tabella 5.1:** Metriche di valutazione della previsione out-of-time.

| Metrica      | Valore                               |
|--------------|--------------------------------------|
| RMSE         | 3.784                                |
| MAE          | 2.237                                |
| MAPE         | $\infty$ (presenza di valori nulli)  |
| ME           | 0.017                                |
| MPE          | $-\infty$ (presenza di valori nulli) |
| Correlazione | 0.018                                |
| MinMax       | 97.81                                |

I valori di RMSE e MAE indicano un errore medio contenuto (circa 2.2–3.8 mm). L’errore medio (ME) è prossimo a zero, segno che il modello non produce distorsioni sistematiche. Il MAPE e l’MPE non sono calcolabili a causa della

presenza di giorni con precipitazione nulla. La correlazione molto bassa (0.018) mostra che il modello non è in grado di riprodurre le oscillazioni giornaliere, limitandosi a catturare il livello medio. Il valore elevato di MinMax (97.81) indica che le previsioni sono fortemente concentrate attorno alla media e non riflettono l'ampia variabilità dei dati reali: un risultato atteso per un modello semplice come ARIMA(1,0,1) applicato a una serie così rumorosa.


## 5.5 Modello SARIMAX

Per includere esplicitamente la componente stagionale, è stato costruito un modello SARIMAX. La scelta dei parametri ottimali è stata effettuata tramite una grid search che ha esplorato diverse combinazioni di  $(p, d, q)$  e  $(P, D, Q, s)$ , con  $s = 12$  (stagionalità annuale), minimizzando il criterio AIC. Il miglior modello individuato è:


$$\text{SARIMAX}(1, 0, 1)(0, 1, 1)_{12}$$

ovvero con una differenziazione stagionale ( $D = 1$ ) e un termine a media mobile stagionale di ordine 1.

Il modello è stato utilizzato per prevedere le precipitazioni per i dodici mesi successivi all'ultima data disponibile (Figura 5.11). La Figura 5.10 mostra invece il confronto tra valori osservati e valori stimati dal modello sull'intero dataset.



**Figura 5.10:** Modello SARIMAX(1,0,1)(0,1,1)<sub>12</sub>: valori osservati e valori stimati.



**Figura 5.11:** Previsione delle precipitazioni per l’anno 2021 con SARIMAX e relativo intervallo di confidenza.

Anche il modello SARIMAX, analogamente al semplice ARIMA, prevede un andamento pressoché costante attorno al valore medio delle precipitazioni, coerente con la natura stazionaria della serie e con la ridotta capacità dei termini autoregressivi e a media mobile di catturare la variabilità giornaliera oltre i primi ritardi. L’intervallo di confidenza si allarga progressivamente, riflettendo l’incertezza crescente con l’orizzonte di previsione.

## 5.6 Conclusioni sull’analisi temporale

L’analisi ha dimostrato che la serie delle precipitazioni giornaliere londinesi è stazionaria e può essere modellata con semplici modelli ARIMA e SARIMAX. Tuttavia, le metriche di valutazione — in particolare la bassissima correlazione e l’elevato valore di MinMax — evidenziano che tali modelli riescono a catturare soltanto il livello medio della serie, senza riprodurre la variabilità giorno per giorno. Questo limite è intrinseco alla natura estremamente rumorosa e poco prevedibile delle precipitazioni giornaliere. La grid search ha comunque confermato che un SARIMAX con ordini  $(1,0,1)(0,1,1)_{12}$  rappresenta il miglior compromesso tra complessità e adattamento ai dati storici.